

# Аудит першоджерел TRPA1 assays: які параметри протоколу можна прийняти без припущень

## Головний висновок

Твоє біологічне зауваження правильне і **суттєво змінює дизайн assay-aware датасету**.

`method + agonist + cell line` описують загальний тип експерименту, але для інтерпретації числового IC50 набагато цікавішими є параметри, які визначають **стан каналу в момент вимірювання**:

**agonist identity → agonist concentration → EC-level → preincubation → application order → assay/readout timing → curve fitting.**

І вже перша ж суворя перевірка першоджерел показала, що ці параметри дійсно різняться між великими TRPA1 assays. Наприклад, в одному великому assay cinnamaldehyde подавався приблизно на **EC50**, 75  $\mu$ M, після 20 хвилин преінкубації; в іншому патентному сімействі — на **EC80**, при цьому в джерелі вказано **10 або 90 хвилин** преінкубації. Це саме той контекст, який губиться, якщо залишити лише `agonist=cinnamaldehyde` та `method=FLIPR`. <sup>1</sup>

Ще важливіше: дослідження виявило проблему, якої я раніше недооцінював. **Однакові або майже однакові описи FLIPR-протоколів повторюються у різних патентах Genentech.** Наприклад, я раніше пов'язував `CHEMBL5737786` з одним схожим патентом лише через збіг тексту протоколу. Тепер source-level перевірка BindingDB показує, що його `src_assay_id=10430` насправді належить **US11236046**, а не тому патенту, який був попередньо припущений. BindingDB показує для entry 10430 саме 202 записи і одну публікацію — US Patent US11236046. <sup>2</sup>

Тобто нове правило має бути ще жорсткішим:

**Збіг тексту Methods недостатній. Спочатку встановлюємо source document / source assay, потім витягуємо параметри.**

Нижче я не даю тобі посилання на ZIP як єдиний результат. **Уся суттєва інформація є прямо в цьому повідомленні.**

## Стан перевірки пріоритетних assays

Я розділив три різні рівні доказовості:

**ACCEPTED** — є першоджерело, assay ↔ source зіставлений достатньо надійно, а значення має дослівний фрагмент.

**MAPPING\_UNCERTAIN** — джерело-кандидат є, але я не можу довести, що конкретний блок Methods відповідає саме цьому ChEMBL assay.

**NO\_ACCESS** — source assay вдалося прив'язати до конкретного патенту, але в поточному проході не отримано достатнього первинного тексту для цитування. У такому разі я навмисно не переносив параметри зі схожих патентів.

| Assay                | Document      | Статус після source audit                                    | Коментар                                                                                            |
|----------------------|---------------|--------------------------------------------------------------|-----------------------------------------------------------------------------------------------------|
| <b>CHEMBL5735476</b> | CHEMBL5727829 | <b>NO_ACCESS / mapping to patent confirmed</b>               | BindingDB entry 9247 → US10711004; пара 5476/5477 разом дає source group                            |
| <b>CHEMBL5733104</b> | CHEMBL5726658 | <b>MAPPING_UNCERTAIN</b>                                     | електрофізіологічний source candidate є, але agonist досі не встановлений                           |
| <b>CHEMBL5737786</b> | CHEMBL5728946 | <b>NO_ACCESS / mapping to patent confirmed</b>               | BindingDB entry 10430 → US11236046                                                                  |
| <b>CHEMBL5735477</b> | CHEMBL5727829 | <b>NO_ACCESS / mapping to patent confirmed</b>               | той самий source group US10711004                                                                   |
| <b>CHEMBL5735475</b> | CHEMBL5727828 | <b>ACCEPTED, але preincubation AMBIGUOUS</b>                 | source family US10710994; primary patent-family text доступний                                      |
| <b>CHEMBL5735474</b> | CHEMBL5727828 | <b>ACCEPTED, але preincubation AMBIGUOUS</b>                 | те саме                                                                                             |
| <b>CHEMBL5736402</b> | CHEMBL5728262 | <b>ACCEPTED</b>                                              | BindingDB entry 9689 → US10913742; повний patent Methods доступний                                  |
| <b>CHEMBL3887573</b> | CHEMBL3886359 | source identified; <b>не приймаю в цей quote-locked pass</b> | EP2717878A1 був знайдений раніше, але тут не переносу параметри без повторної quote-level перевірки |
| <b>CHEMBL5734964</b> | CHEMBL5727588 | <b>ACCEPTED</b>                                              | патентне сімейство US10584116B2; таблиця має 51 hTRPA1 IC50, як і assay                             |
| <b>CHEMBL5318377</b> | CHEMBL5316309 | source article identified; quote audit incomplete            | BAY-390 article                                                                                     |

| Assay                | Document      | Статус після source audit                         | Коментар                                                                                                    |
|----------------------|---------------|---------------------------------------------------|-------------------------------------------------------------------------------------------------------------|
| <b>CHEMBL3299551</b> | CHEMBL3297713 | <b>PARTIAL</b>                                    | першоджерело J. Med. Chem. знайдене; є evidence для порядку додавання/10 min, але не беру неперевірені поля |
| <b>CHEMBL5735742</b> | CHEMBL5727953 | <b>MAPPING_UNCERTAIN</b>                          | generic patent FLIPR protocol недостатній для source assignment                                             |
| <b>CHEMBL2071976</b> | CHEMBL2069204 | source article identified; quote audit incomplete | Nyman et al. 2013                                                                                           |
| <b>CHEMBL3789590</b> | CHEMBL3784976 | source article identified; quote audit incomplete | AM-0902 study                                                                                               |
| <b>CHEMBL2071975</b> | CHEMBL2069204 | source article identified; quote audit incomplete | Nyman et al. 2013                                                                                           |
| <b>CHEMBL5739043</b> | CHEMBL5729590 | <b>MAPPING_UNCERTAIN</b>                          | Ca6/AITC patent assay; джерело ще треба lock-нути                                                           |
| <b>CHEMBL4036813</b> | CHEMBL4033760 | <b>MAPPING_UNCERTAIN</b>                          | PatchXpress assay; первинний document mapping не доведений                                                  |
| <b>CHEMBL5737489</b> | CHEMBL5728802 | <b>MAPPING_UNCERTAIN</b>                          | дуже схожий Ca6/AITC protocol, але саме тому не переносив між patents                                       |
| <b>CHEMBL3300585</b> | CHEMBL3297644 | source not sufficiently verified                  | не приймаю ChEMBL-description як первинний доказ                                                            |
| <b>CHEMBL1944172</b> | CHEMBL1938315 | source not sufficiently verified                  | те саме                                                                                                     |

Особливо сильні source mappings вдалося зробити через BindingDB:

- `src_assay_id 9689` має **110 hits**, одну publication і прямо прив'язаний до **US10913742**. <sup>3</sup>
- `src_assay_id 10430` має **202 hits** і прямо прив'язаний до **US11236046**. <sup>2</sup>
- `src_assay_id 9247` має **455 hits** і прямо прив'язаний до **US10711004**. <sup>4</sup>

Останній пункт важливий для твоєї спеціальної пари. У raw snapshot `CHEMBL5735476` і `CHEMBL5735477` разом мають **455 exact IC50 records (281 + 174)**; це рівно збігається з 455 affinity records BindingDB entry 9247. Отже, **document/source group ми зафіксували дуже добре**. Але це ще не говорить, яка саме колонка/умова патенту відповідає кожному assay. BindingDB лише підтверджує, що весь блок належить US10711004. <sup>5</sup>

## Протоколи, які вже можна прийняти

Нижче діє твоє правило буквально. Для кожного джерела я спочатку задаю короткі **дослівні quote keys**, а потім кожне прийняте поле посилається на конкретний quote key. Це також не дозволяє мені непомітно перетворити інтерпретацію на «цитату».

### CHEMBL5736402 — ACCEPTED

**Document:** CHEMBL5728262

**Source assay:** 9689\_1\_po1\_7258

**Primary source:** US10913742, *Oxadiazolones as transient receptor potential channel inhibitors*. BindingDB прямо прив'язує entry 9689 до US10913742. <sup>6</sup>

Patent Example 2 містить саме TRPA1 IC50 protocol і таблицю hTRPA1 IC50. <sup>7</sup>

**Дослівні quote keys із першоджерела:**

- **Q1:** "CHO cells"
- **Q2:** "FLIPR Tetra"
- **Q3:** "BD calcium indicator dye"
- **Q4:** "20 minutes"
- **Q5:** "EC50"
- **Q6:** "cinnamaldehyde (75 uM)"
- **Q7:** "prior to adding agonist"
- **Q8:** "Hill coefficient (n) fixed to 1.5"

Ці фрагменти знаходяться в безпосередньо послідовних paragraphs Example 2. <sup>8</sup>

```
assay_chembl_id: CHEMBL5736402

challenge_agonist:
  cinnamaldehyde
  evidence: Q6

agonist_concentration:
  75 µM for human TRPA1
  evidence: Q6
  note: source separately gives 45 µM for rat TRPA1

agonist_level:
  approximately EC50
  evidence: Q5 + Q6

compound_preincubation_min:
  20
  evidence: Q4 + Q7

readout_method:
  FLIPR Tetra calcium-flux assay
  evidence: Q2
```

```

    source context explicitly describes block of cinnamaldehyde-induced
    calcium influx

dye_or_indicator:
    BD calcium indicator dye
    evidence: Q3

cell_line:
    CHO
    evidence: Q1

species_construct:
    human TRPA1
    evidence: source paragraph specifies human and rat TRPA1;
               concentration phrase Q6 explicitly identifies the human
condition
    WT status: NOT_FOUND

temperature:
    NOT_FOUND
    note: room temperature is explicitly stated for compound incubation,
          but I do not equate that automatically with measurement temperature

application_order:
    compound BEFORE agonist
    evidence: Q7

curve_fitting:
    Hill fit; Hill coefficient n fixed to 1.5
    evidence: Q8

n_replicates:
    NOT_FOUND

```

Це дуже корисний assay для нашої статті: **75  $\mu\text{M}$  cinnamaldehyde** тут названо приблизно EC50, а не EC80. Patent також прямо говорить про 20-хвилинну preincubation. <sup>7</sup>

Отже майбутня ознака не повинна бути просто:

```
agonist = cinnamaldehyde
```

а щонайменше:

```

agonist = cinnamaldehyde
agonist_concentration_uM = 75
agonist_level = EC50
preincubation_min = 20

```

## CHEMBL5735474 — ACCEPTED, але час неоднозначний

**Document:** ChEMBL5727828

**Source:** patent family corresponding to US10710994. Primary patent-family full text містить TRPA1 FLIPR protocol. У ньому human TRPA1 IC50 визначали на CHO/FLIPR із BD calcium dye, але два compound incubation times записані в одному protocol. <sup>9</sup>

### Quote keys:

- **Q1:** "CHO cells"
- **Q2:** "FLIPR"
- **Q3:** "BD calcium"
- **Q4:** "10 minutes or 90 minutes"
- **Q5:** "EC80"
- **Q6:** "cinnamaldehyde"
- **Q7:** "before adding the agonist"
- **Q8:** "Hill coefficient"
- **Q9:** "fixed at 1.5"
- **Q10:** "room temperature"

У першоджерелі compound incubation прямо подано як альтернативу: **10 або 90 хвилин**, а після неї додається приблизно EC80 cinnamaldehyde. <sup>9</sup>

```
assay_chembl_id: ChEMBL5735474
```

```
challenge_agonist:
  cinnamaldehyde
  evidence: Q6
```

```
agonist_concentration:
  75 [source reports "(75)" in this protocol]
  evidence: source phrase containing Q5 + Q6
  unit:
    source context is concentration protocol; however I do not silently
    normalize the typography beyond what primary text states
```

```
agonist_level:
  approximately EC80
  evidence: Q5
```

```
compound_preincubation_min:
  AMBIGUOUS: 10 or 90
  evidence: Q4 + Q7
```

```
readout_method:
  FLIPR calcium-influx assay
  evidence: Q2
  source explicitly states measurement of cinnamaldehyde-induced calcium
  influx
```

```
dye_or_indicator:
```

```
BD calcium indicator dye
evidence: Q3

cell_line:
  CHO
  evidence: Q1

species_construct:
  human TRPA1
  evidence: primary protocol identifies the human TRPA1 channel
  WT status: NOT_FOUND

temperature:
  room temperature DURING compound incubation
  evidence: Q10
  measurement temperature: NOT_FOUND

application_order:
  compound BEFORE agonist
  evidence: Q7

curve_fitting:
  Hill coefficient n fixed at 1.5
  evidence: Q8 + Q9

n_replicates:
  NOT_FOUND
```

### CHEMBL5735475 — ACCEPTED, але час так само неоднозначний

Це той самий document CHEMBL5727828 і той самий первинний protocol block. Тому **я не маю права вибрати 90 хвилин лише тому, що ChEMBL назвав assay “FLIPR Assay (90 minutes)”**.

Первинний текст каже саме:

**Q4: “10 minutes or 90 minutes”.** 9

Тому результат:

```
assay_chembl_id: CHEMBL5735475

challenge_agonist:
  cinnamaldehyde
  evidence: Q6

agonist_concentration:
  75 [as reported in primary protocol]
  evidence: primary EC80/cinnamaldehyde passage

agonist_level:
```

```

    approximately EC80
    evidence: Q5

compound_preincubation_min:
    AMBIGUOUS: 10 or 90
    evidence: Q4 + Q7

readout_method:
    FLIPR calcium-influx assay
    evidence: Q2

dye_or_indicator:
    BD calcium indicator dye
    evidence: Q3

cell_line:
    CHO
    evidence: Q1

species_construct:
    human TRPA1
    WT status: NOT_FOUND

temperature:
    room temperature DURING compound incubation
    evidence: Q10
    measurement temperature: NOT_FOUND

application_order:
    compound BEFORE agonist
    evidence: Q7

curve_fitting:
    Hill coefficient n fixed at 1.5
    evidence: Q8 + Q9

n_replicates:
    NOT_FOUND

```

І тут з'явилася **потенційно важлива розбіжність ChEMBL ↔ source**.

У первинному патентному тексті є:

- dye load;
- потім **15 хвилин** охолодження/витримки plate при кімнатній температурі;
- але compound preincubation — **10 або 90 хвилин**. <sup>9</sup>

Тому назву ChEMBL `FLIPR Assay (15 minutes)` **не можна автоматично трактувати як 15-minute compound preincubation**.

Це саме та помилка, яку легко було б внести в ML feature table, читаючи лише ChEMBL description.

## CHEMBL5734964 — ACCEPTED і дуже добре документований

**Document:** ChEMBL5727588

**Primary patent family:** US10584116B2, *Heterocyclic sulfonamide derivative and medicine containing same*. Первинний patent text дає повну cell preparation, TRPA1 transfection, dye loading, порядок додавання і calculation of antagonist activity. <sup>10</sup>

Особливо сильна mapping-перевірка: patent Table 5 містить послідовність **51 hTRPA1 IC50 examples**, а наш assay також має 51 exact IC50 record; перші значення та діапазон у snapshot узгоджуються з patent table. Patent прямо показує, наприклад, 0.016, 0.026, 0.0073  $\mu\text{M}$  тощо. <sup>11</sup>

### Quote keys:

- **Q1:** "human TRPA1 expression plasmid"
- **Q2:** "293T cells"
- **Q3:** "FLIPR Calcium4 Assay Kit"
- **Q4:** "After 10 min"
- **Q5:** "allyl isothiocyanate solution"
- **Q6:** "100  $\mu\text{M}$  allyl isothiocyanate"
- **Q7:** "sigmoid approximate curve by XLfit"

Усі вони знаходяться у безпосередньому Experimental Example protocol. <sup>12</sup>

```
assay_chembl_id: ChEMBL5734964
```

```
challenge_agonist:  
  allyl isothiocyanate (AITC)  
  evidence: Q5
```

```
agonist_concentration:  
  100  $\mu\text{M}$  in the prepared AITC solution  
  evidence: Q6
```

```
IMPORTANT:  
final well concentration = NOT_FOUND
```

```
I do NOT calculate final concentration from dispensing volumes,  
because that would be an inference rather than a directly reported  
parameter.
```

```
agonist_level:  
  NOT_FOUND
```

```
compound_preincubation_min:  
  10  
  evidence: Q4 + Q5
```

```
readout_method:  
  intracellular-calcium fluorescence on FDSS7000  
  evidence: primary section "Measurement of Intracellular Calcium"
```

```

Increase";
    Q3 identifies the calcium assay reagent
    instrument:
        FDSS7000

dye_or_indicator:
    FLIPR Calcium4 Assay Kit
    evidence: Q3

cell_line:
    293T
    evidence: Q2

species_construct:
    transiently expressed human TRPA1
    evidence: Q1
    source describes introduction of the human TRPA1 expression plasmid into
    293T cells
    WT status:
        NOT_FOUND as an explicit "wild-type" statement

temperature:
    measurement temperature: NOT_FOUND

application_order:
    test compound BEFORE AITC
    evidence: Q4 + Q5

curve_fitting:
    IC50 from a sigmoid approximate curve using XLfit
    evidence: Q7

n_replicates:
    NOT_FOUND

```

Тут є ще один методологічно важливий момент.

Patent каже, що **AITC solution** була 100  $\mu\text{M}$ . Він також дає об'єми до і після додавання. Математично можна було б розрахувати кінцеву концентрацію в well, але за твоїм правилом я цього **не роблю**. У feature table повинно стояти щось на кшталт:

```

agonist_concentration_reported = 100
agonist_concentration_reported_unit = uM
agonist_concentration_basis = prepared_solution
agonist_final_concentration_uM = NOT_FOUND

```

А не придумане «20  $\mu\text{M}$  final».

Це дуже хороший приклад того, навіщо нам provenance-aware extraction.

## Спеціальні проблемні assays

### CHEMBL5735476 / CHEMBL5735477

Тут є прогрес, але я не буду удавати, що проблему вирішено.

BindingDB `entryid=9247` містить 455 TRPA1 affinity records і однозначно називає джерело **US Patent US10711004 (2020)**. <sup>5</sup>

У нашому raw ChEMBL snapshot:

```
CHEMBL5735476 exact IC50 records = 281
CHEMBL5735477 exact IC50 records = 174

total = 455
```

Тобто source mapping:

```
CHEMBL5735476 + CHEMBL5735477
      ↓
BindingDB assay family 9247
      ↓
US10711004
```

практично зафіксований.

Але завдання було складніше: **визначити, яка колонка/час у US10711004 відповідає 5735476, а яка 5735477.**

Цього я на цьому проході не підтвердив первинною таблицею.

Тому:

```
CHEMBL5735476
challenge_agonist      = NO_ACCESS
agonist_concentration  = NO_ACCESS
agonist_level          = NO_ACCESS
compound_preincubation_min = NO_ACCESS
readout_method         = NO_ACCESS
dye_or_indicator       = NO_ACCESS
cell_line              = NO_ACCESS
species_construct      = NO_ACCESS
temperature            = NO_ACCESS
application_order      = NO_ACCESS
curve_fitting          = NO_ACCESS
n_replicates           = NO_ACCESS
```

```
mapping_note:
  source patent US10711004 confirmed;
  assay-specific protocol column not confirmed.
```

і абсолютно те саме для CHEMBL5735477.

**Я свідомо не переніс 10/90 min із CHEMBL5727828**, хоча протокол дуже схожий. Це інший patent/ source entry. Саме таку заборону ти встановив — і вона тут виявилася виправданою. Source entry 9247 належить US10711004, тоді як інші аналогічні FLIPR datasets походять з інших patent records.

13

## CHEMBL5737786

Тут ми виправили мою попередню потенційно небезпечну помилку.

```
src_assay_id = 10430_1_pol_7258.
```

BindingDB entry 10430:

**202 hits**, Human TRPA1, Genentech, US Patent.

І фільтр publication показує рівно одну publication:

**US Patent US11236046 (2022).** 2

Це чудово узгоджується з raw snapshot, де CHEMBL5737786 має **202 exact IC50 records**.

Тобто mapping дуже сильний.

Але primary US11236046 Methods цього разу не вдалося отримати в достатньому вигляді для дослівного quote audit.

Тому, попри те що існує надзвичайно схожий Genentech patent protocol з:

```
CHO
FLIPR
BD calcium dye
20 min
cinnamaldehyde
75 µM
```

**я нічого з цього не переносу в CHEMBL5737786.**

Результат:

```
CHEMBL5737786
source = US11236046
```

```

mapping = CONFIRMED

challenge_agonist      = NO_ACCESS
agonist_concentration  = NO_ACCESS
agonist_level          = NO_ACCESS
compound_preincubation_min = NO_ACCESS
readout_method         = NO_ACCESS
dye_or_indicator       = NO_ACCESS
cell_line              = NO_ACCESS
species_construct      = NO_ACCESS
temperature            = NO_ACCESS
application_order      = NO_ACCESS
curve_fitting          = NO_ACCESS
n_replicates           = NO_ACCESS

```

Це, до речі, демонструє, чому попередня автоматична extraction-логіка була небезпечною:  
**protocol similarity  $\neq$  assay identity.**

### CHEMBL5733104 — найбільший electrophysiology assay

Це залишається найбільш цікавою прогалиною.

У ChEMBL це whole-cell electrophysiology/patch-clamp assay. Попередній пошук виводив на patent-family text із EPC-9/EPC-10/Patchmaster-подібним protocol, але в цьому проході я **не встановив source patent на рівні, достатньому для прийняття параметрів.**

Тому не можна написати:

```
challenge_agonist = AITC
```

або:

```
challenge_agonist = cinnamaldehyde
```

лише тому, що це типові TRPA1 agonists.

Статус:

```

CHEMBL5733104

source_mapping:
  MAPPING_UNCERTAIN

challenge_agonist:
  MAPPING_UNCERTAIN
note:
  no accepted primary-source quote naming the activating stimulus

```

```

agonist_concentration:
  MAPPING_UNCERTAIN

agonist_level:
  MAPPING_UNCERTAIN

compound_preincubation_min:
  MAPPING_UNCERTAIN

readout_method:
  MAPPING_UNCERTAIN
note:
  ChEMBL says whole-cell electrophysiology,
  but ChEMBL description is not accepted as primary-source evidence
  here.

dye_or_indicator:
  MAPPING_UNCERTAIN

cell_line:
  MAPPING_UNCERTAIN

species_construct:
  MAPPING_UNCERTAIN

temperature:
  MAPPING_UNCERTAIN

application_order:
  MAPPING_UNCERTAIN

curve_fitting:
  MAPPING_UNCERTAIN

n_replicates:
  MAPPING_UNCERTAIN

```

Тобто **найбільший assay без challenge information** залишається без **challenge information**, а не отримує правдоподібний agonist «для повноти».

## Що вже видно для майбутнього ML-датасету

Для чотирьох assays, де я вже приймаю quote-locked protocol extraction, coverage така:

| Параметр          | Знайдено | Коментар                |
|-------------------|----------|-------------------------|
| challenge_agonist | 4/4      | cinnamaldehyde або AITC |

| Параметр                   | Знайдено       | Коментар                                                                    |
|----------------------------|----------------|-----------------------------------------------------------------------------|
| agonist_concentration      | 4/4            | але для 5734964 це concentration of prepared solution, не гарантовано final |
| agonist_level              | 3/4            | EC80 / EC50 / NOT_FOUND                                                     |
| compound_preincubation_min | 4/4            | 20; 10; або AMBIGUOUS: 10 or 90                                             |
| readout_method             | 4/4            | FLIPR/calcium або FDSS calcium fluorescence                                 |
| dye_or_indicator           | 4/4            | BD calcium indicator або FLIPR Calcium4                                     |
| cell_line                  | 4/4            | CHO або 293T                                                                |
| species_construct          | 4/4            | human TRPA1, але explicit WT часто відсутній                                |
| temperature                | 3/4<br>partial | температура incubation відома;<br>measurement temperature часто ні          |
| application_order          | 4/4            | compound → agonist                                                          |
| curve_fitting              | 4/4            | fixed Hill coefficient або sigmoid/XLfit                                    |
| n_replicates               | 0/4            | поки ніде не знайшов explicit n                                             |

І вже цих чотирьох достатньо, щоб я **переглянув попередню структуру context features**.

Я більше не ставив би:

```
method
agonist
cell_line
```

як три «головні» assay features.

Для нашого біологічного питання логічніша ієрархія:

```
Tier A – potency-defining context
challenge_agonist
agonist_concentration
agonist_concentration_basis
agonist_level
compound_preincubation_min
application_order

Tier B – measurement kinetics / analysis
readout_window_min      [коли source дозволяє]
measurement_temperature
curve_fitting
hill_coefficient_fixed
hill_coefficient_value
n_replicates
```

```
Tier C – technical assay context
  readout_method
  dye_or_indicator
  cell_line
  species_construct
```

Причому навіть `agonist_concentration` треба розбити щонайменше на:

```
agonist_concentration_value
agonist_concentration_unit
agonist_concentration_basis =
  final_well
  prepared_solution
  nominal
  NOT_FOUND
```

Інакше 100  $\mu\text{M}$  stock/prepared solution та 100  $\mu\text{M}$  final concentration будуть помилково однаковою ML-ознакою.

Так само `temperature` треба розділяти:

```
compound_preincubation_temperature
measurement_temperature
```

а не робити одне поле `temperature`.

І я б **узагалі відмовився від старого** `time_param`. У ньому біологічно несумісні речі. Потрібні окремі:

```
compound_preincubation_min
agonist_exposure_before_readout_min
readout_window_min
dye_loading_min
```

## Найважливіша знайдена розбіжність

Поки що найсильніша QC-знахідка — не конкретне число, а **семантична пастка з “15 minutes”**.

У patent-family protocol для `CHEMBL5735474/5735475` першоджерело описує:

- 1 h dye loading;
- потім 15 min при room temperature;
- потім compound;
- потім **10 min або 90 min** compound incubation;
- потім agonist. <sup>9</sup>

Тому якщо ChEMBL assay названо:

FLIPR Assay (15 minutes)

це **не дає нам права записати**

compound\_preincubation\_min = 15

без прив'язки до конкретної source table.

Ця одна знахідка вже виправдовує ручний source audit.

## Підсумок аудиту і рішення для статті

На цьому суворому проході я **не заповнював 20 assays правдоподібними значеннями**. Замість цього маємо:

**Повністю прийняті на quote-level зараз:**

CHEMBL5735474  
CHEMBL5735475  
CHEMBL5736402  
CHEMBL5734964

Для 5735474/5735475 preincubation навмисно залишається:

AMBIGUOUS: 10 or 90

**Source mapping підтверджено, але primary assay-specific parameters не прийняті через відсутність достатнього первинного тексту:**

CHEMBL5735476 → US10711004  
CHEMBL5735477 → US10711004  
CHEMBL5737786 → US11236046

BindingDB source-level evidence для цих mapping є сильним: 9247 → US10711004 і 10430 → US11236046. <sup>14</sup>

**Залишається mapping problem:**

CHEMBL5733104

і agonist для нього **не встановлений**.

Documents/source families identified, але я не зараховую параметри без завершеного quote audit:

CHEMBL3887573  
CHEMBL5318377  
CHEMBL3299551  
CHEMBL2071975  
CHEMBL2071976  
CHEMBL3789590

Ще не можна надійно source-map:

CHEMBL5735742  
CHEMBL5739043  
CHEMBL4036813  
CHEMBL5737489  
CHEMBL3300585  
CHEMBL1944172

Найважливіший стратегічний результат цього дослідження такий:

**Не треба зараз будувати folds. Спочатку треба закінчити protocol provenance table.**

Бо ми щойно побачили, що основна explanatory variable статті може бути не `method`, а, наприклад:

cinnamaldehyde 75  $\mu$ M @ EC50 + 20 min preincubation

проти

cinnamaldehyde ~75 @ EC80 + 10/90 min preincubation

проти

AITC, reported 100  $\mu$ M prepared solution + 10 min preincubation

Це вже набагато ближче до реального біологічного питання: **чи пояснює protocol state частину міжassayної варіабельності IC50**. Первинні джерела прямо підтверджують існування таких відмінностей. <sup>15</sup>

І, мабуть, найцінніший методологічний принцип для майбутньої статті можна вже сформулювати так:

**Кожна assay-context feature повинна мати provenance: source document, exact quote, mapping status і missingness reason.**

Без цього assay-aware модель ризикує навчатися не на експериментальному контексті, а на наших припущеннях про нього.

---

1 7 8 <https://patents.google.com/patent/US10913742>

<https://patents.google.com/patent/US10913742>

2 14 [https://bindingdb.org/rwd/jsp/dbsearch/PrimarySearch\\_ki.jsp?entryid=10430&tag=entry](https://bindingdb.org/rwd/jsp/dbsearch/PrimarySearch_ki.jsp?entryid=10430&tag=entry)

[https://bindingdb.org/rwd/jsp/dbsearch/PrimarySearch\\_ki.jsp?entryid=10430&tag=entry](https://bindingdb.org/rwd/jsp/dbsearch/PrimarySearch_ki.jsp?entryid=10430&tag=entry)

3 6 [https://bindingdb.org/rwd/jsp/dbsearch/PrimarySearch\\_patent.jsp?](https://bindingdb.org/rwd/jsp/dbsearch/PrimarySearch_patent.jsp?patent=US10913742&patent_submit=Search)

[patent=US10913742&patent\\_submit=Search](https://bindingdb.org/rwd/jsp/dbsearch/PrimarySearch_patent.jsp?patent=US10913742&patent_submit=Search)

[https://bindingdb.org/rwd/jsp/dbsearch/PrimarySearch\\_patent.jsp?patent=US10913742&patent\\_submit=Search](https://bindingdb.org/rwd/jsp/dbsearch/PrimarySearch_patent.jsp?patent=US10913742&patent_submit=Search)

4 5 13 [https://bindingdb.org/rwd/jsp/dbsearch/PrimarySearch\\_ki.jsp?entryid=9247&tag=entry](https://bindingdb.org/rwd/jsp/dbsearch/PrimarySearch_ki.jsp?entryid=9247&tag=entry)

[https://bindingdb.org/rwd/jsp/dbsearch/PrimarySearch\\_ki.jsp?entryid=9247&tag=entry](https://bindingdb.org/rwd/jsp/dbsearch/PrimarySearch_ki.jsp?entryid=9247&tag=entry)

9 15 <https://patents.google.com/patent/BR112020018983A2/en>

<https://patents.google.com/patent/BR112020018983A2/en>

10 11 12 <https://patents.google.com/patent/US10584116B2/en>

<https://patents.google.com/patent/US10584116B2/en>